

50 Preguntas Técnicas de CI (Continuous Integration) — Respuestas Completas

1. ¿Qué es Continuous Integration (CI) y cuál es su objetivo?

Práctica de integrar código frecuentemente en un repositorio compartido y ejecutar validaciones automáticas.

Objetivo: **detectar errores temprano y mantener el código siempre desplegable.**

2. Beneficios de CI en proyectos de datos

- Previene fallas en producción
 - Automatiza tests de SQL, ETL, modelos y pipelines
 - Valida esquemas, linaje y dependencias
 - Acelera desarrollo y revisiones
 - Mejora calidad del código y del dato
-

3. Herramientas de CI

GitHub Actions, GitLab CI, Jenkins, CircleCI, Azure Pipelines, Bitbucket Pipelines, Argo Workflows.

4. ¿Qué es un pipeline CI y qué etapas tiene?

Secuencia automatizada:

- Checkout
- Linting
- Tests
- Build
- Validación

- Generación de artifacts
 - Notificaciones
-

5. ¿Qué son los runners?

Máquinas que ejecutan jobs del pipeline. Pueden ser:

- Hosted (cloud)
 - Self-hosted (on-premise o personalizados)
-

6. Trigger de CI y tipos

Evento que inicia el pipeline:

- push
 - pull/merge request
 - schedule
 - manual
 - cambios en rutas específicas
-

7. Linting

Análisis del estilo de código para asegurar consistencia y buenas prácticas.

8. Static code analysis

Análisis automático de vulnerabilidades, bugs y malas prácticas sin ejecutar el código.

9. Build en CI

Proceso para empaquetar código o compilar artefactos (contenedores, wheels, ejecutables).

10. Artifacts

Archivos generados por el pipeline: builds, reportes, logs, documentación.

11. Cache dependencies

Caché de librerías para acelerar pipelines (pip, npm, maven, dbt deps).

12. Pipeline reproducible

- Versionar dependencias
 - Usar containers
 - Pinning de versiones
 - Variables inmutables
-

13. Pipeline as code

Definición del pipeline en archivos dentro del repositorio (YAML).

14. Archivo de configuración (.yaml)

Documento que define jobs, stages, triggers, variables y condiciones del pipeline.

15. Stages en CI

Agrupaciones lógicas: build, test, validate, release, deploy.

16. Paso pre-deploy

Validaciones antes de desplegar: tests, validación de esquema, linting, dry-run.

17. Ejecutar pruebas automáticas

Usar frameworks: pytest, unittest, pytest-dbt, sqlfluff, datafold.

18. Medir duración del pipeline

Herramientas integradas en GitHub/GitLab o dashboards externos (Datadog, Grafana).

19. Parallel jobs

Ejecución simultánea de tareas para acelerar el pipeline.

20. Optimizar pipelines lentos

- Cache
 - Paralelismo
 - Saltar etapas innecesarias
 - Reutilizar artifacts
 - Jobs condicionales
-

21. Branch protection

Reglas que impiden merges directos sin pasar tests, revisiones, o approvals.

22. Merge requests / Pull requests

Solicitudes para integrar cambios con revisiones, CI y comentarios.

23. Integrar CI con repos privados

Mediante tokens, deploy keys, o identity federation.

24. Manejar secretos en CI

Variables protegidas, vaults, secret managers (AWS, GCP, Azure).

25. Variables protegidas vs no protegidas

- **Protegidas:** solo para ramas protegidas (main, releases).
 - **No protegidas:** disponibles en ramas normales.
-

26. CI badge

Icono en el README que muestra el estado del pipeline (passing/failing).

27. Test coverage

Porcentaje de código cubierto por tests.

28. Calcular cobertura

Usar herramientas: pytest-cov, coverage.py, nyc, sonarcloud.

29. Pipeline monolítico vs modular

- **Monolítico:** un solo archivo grande.
 - **Modular:** múltiples archivos heredados, plantillas y jobs reusables.
-

30. Fan-in / Fan-out

- **Fan-out:** un job genera múltiples jobs en paralelo.
 - **Fan-in:** varios jobs deben completarse para continuar.
-

31. Entornos dev/test/prod

Usar variables, job rules y matrices para ejecutar pipelines específicos por entorno.

32. Matrix builds

Ejecutar combinaciones:

- versiones de Python
 - diferentes motores (Spark, Snowflake, BigQuery)
 - sistemas operativos
-

33. Commitlint

Reglas para formatear mensajes de commit correctamente.

34. Semantic versioning

Formato **MAJOR.MINOR.PATCH** para versionar software.

35. ¿Cómo CI previene errores en producción?

- Pruebas automatizadas
 - Validación de esquemas
 - Linting
 - Revisiones automáticas
 - Detectar regresiones temprano
-

36. Dry-run

Simulación de una ejecución sin aplicar cambios.

37. Rollback plan

Procedimiento documentado para revertir despliegues en caso de fallo.

38. Versionar modelos de datos con CI

Checks automáticos de esquemas, migraciones, pruebas y validación de breaking changes.

39. Integrar CI con dbt

- Ejecutar `dbt deps`, `dbt test`, `dbt build`
 - Validar documentación
 - Ejecutar `tests custom`
-

40. Automated documentation generation

Generar documentación automáticamente: `dbt docs`, Sphinx, MkDocs, Javadoc.

41. Dependencias entre pipelines

Usar triggers, artifacts, o pipelines padres/hijos.

42. CI idempotente

Múltiples ejecuciones generan el **mismo resultado**.

43. Detectar regresiones automáticamente

Comparar resultados de tests, linters, métricas o snapshots previos.

44. Artifact retention policy

Tiempo que se conservarán artifacts antes de ser eliminados.

45. Ejecutar pipelines solo si cambia una carpeta

Usar reglas:

- `paths` (GitHub Actions)
 - `changes` (GitLab CI)
-

46. Monorepo CI

Pipeline diseñado para múltiples proyectos dentro de un mismo repositorio.

47. Container-based CI

Ejecutar jobs dentro de contenedores para asegurar reproducibilidad.

48. On-premise CI vs cloud CI

- **On-premise:** control total, más mantenimiento.
 - **Cloud:** escalable, menos administración.
-

49. Métricas para evaluar CI

- Duración

- Estabilidad
 - Frecuencia de ejecuciones
 - Porcentaje de fallos
 - Cobertura
 - Tiempo de merge
-

50. Buenas prácticas de CI para equipos de datos

- Tests de calidad de datos
- Linting SQL y Python
- Validación de esquemas
- Monitoreo de breaking changes
- Pipelines rápidos y modulares
- Uso estricto de branch protection